

TAXOCLASS (NAACL 2021) 재현·확장 · AMAZON-531

모델은 그대로, 데이터만 고쳤다

라벨 0개에서 531-클래스 계층 멀티라벨 분류기를 학습하고,
성능 병목이 모델이 아니라 **silver label 품질**임을 실험으로 규명한 기록

Nayeon Kim

Weakly-Supervised HMTC · Amazon-531 (train 29,487 / test 19,658) · 개인 100% · GitHub

Example-F1
(test)


0.3995 →
0.5488

zero-shot 대비 +8.7pt · 초기 분류기 대비 +14.9pt
논문 TaxoClass-NoST(0.5431) 상회

모델이 아니라 데이터가 병목이었다

라벨 0개로 학습한 531-클래스 계층 분류기 — 다섯 지점의 가설·검증 기록

각 막대 = 하나의 가설을 검증한 결과 · Test Example-F1 · seed 고정



성능을 바꾼 네 가지 판단

라벨 구조부터 의심했다

예측 공간 축소

2⁵³¹ → 568 경로

1

지표부터 다시 측정했다

문서→라벨 단위 precision

71% → 30.3%

2

LLM은 중요한 문서에만

결정 경계 10K건 재검수

43% → 49%

3

Validation으로 멈췄다

self-training stopping

+1.2pt → +3.1pt

4

모델은 그대로. 데이터만 고쳤다 — 위 다섯 지점이 그 기록이다.

잘못 고른 품질 지표가 문제를 가리고 있었다

가설 → 실험 → 실패 → 원인 분석 → 재실험 — 병목을 데이터로 좁혀간 과정

같은 데이터, 평가 지표만 바꿨다

문서 단위 Hit Rate

71%

문서당 정답 ≥ 1개 포함 비율 — 양호해 보였다

라벨 단위 Precision

30.3%

생성 라벨 중 실제 정답 비율 — 실제 품질


문서당 평균 3.8개 라벨 생성

정답 1.1

오답 2.7개

→ 문서에 정답이 하나라도 있으면 "양호"로 세어, 함께 생성된 2.7개의 오답이 지표에 가려졌다.

threshold는 감이 아니라 곡선으로 결정했다



PROBLEM

학습한 분류기 0.3995

< zero-shot 0.4623 —
학습이 성능을 깎았다

가설 1 · 기각

학습 설정 문제?

batch-seq len-decoder
통제 → 모두 1pt 미만

가설 2

데이터 품질 문제?

지표 재정의 → 라벨 단위
precision 30.3%

원인

지표가 가리고 있었다

문서 단위 71%가
과잉 생성을 은폐

재실험

min_conf 0.15 + len 512

silver 30 → 43% ·
Example-F1 +6.2pt

평가 지표를 다시 정의하는 순간, 보이지 않던 6pt 규모의 문제가 드러났다.

0.3995 → 0.5488, 각 개입의 기여분을 대조로 분리했다

모든 대조 = 해당 개입만 교체 · 나머지 조건·seed 고정 — Decision Log가 아니라 Contribution Analysis

귀속 ① 데이터 정제


+6.2pt

귀속 ② LLM 재검수

+5.7pt

귀속 ③ validation stopping

+3.1pt



silver precision과 F1이 동행 — 병목은 데이터



1K은 0pt · 임계 규모 위에서만 효과



멈추는 기준이 이득의 절반을 갈랐다

측정 조건 공개

- 최종 0.5488의 stopping 신호는 train gold 3,000개를 사용한다(학습 신호로는 미사용). 순수 weak-supervision 세팅 최고치는 **0.5180**으로 분리 보고.
- test 피크 0.5492는 채택하지 않았다 — 결과를 본 뒤 고르면 test 튜닝이 되므로, validation 규칙이 정한 **0.5488**을 보고.
- 참조(논문 보고치): **TaxoClass-NoST 0.5431** (상회) · full(완전지도) 0.5934 · Hier-0Shot-TC 0.4742